

股票涨跌方向预测

——基于机器学习分类模型的金融时间序列预测研究报告

标的资产：兆易创新（603986.SH）

数据范围：2022-01-04 ~ 2026-07-09

报告日期：2026年07月16日

目 录

- 一、项目背景与目标
- 二、数据概览与探索性分析
- 三、方法论
 - 3.1 特征工程
 - 3.2 标签构造
 - 3.3 Purged Walk-Forward 交叉验证
- 四、模型评估与分析
 - 4.1 逻辑回归 (Logistic Regression)
 - 4.2 随机森林 (Random Forest)
 - 4.3 XGBoost
 - 4.4 支持向量机 (SVC)
- 五、模型横向对比
- 六、结论与建议

一、项目背景与目标

股票价格方向预测是量化金融领域的经典问题，其核心挑战在于金融时间序列的低信噪比和非平稳特性。本报告以兆易创新（603986.SH）2022 年 1 月至 2026 年 7 月的日线交易数据为研究对象，构建四种机器学习分类模型——逻辑回归（Logistic Regression）、随机森林（Random Forest）、XGBoost 和支持向量机（SVC），对其未来 20 个交易日的涨跌方向进行分类预测。

本项目采用 Purged Walk-Forward Cross-Validation（时间序列交叉验证）作为评估框架，有效避免了未来信息泄露问题。通过对比四个模型在 ROC 曲线、AUC 值、年化收益率、夏普比率和胜率等维度的表现，筛选出适合该标的的预测模型。

二、数据概览与探索性分析

原始数据包含兆易创新自 2022 年 1 月 4 日至 2026 年 7 月 8 日共计 1091 个交易日的日线数据，字段包括开盘价、收盘价、最高价、最低价、昨收价、涨跌幅、成交量和成交额等。样本期内日均涨跌比约为 48.9%:51.1%，基本平衡；年化波动率达 53.13%，属于高波动科技股品种，为机器学习模型提供了丰富的价格形态信息。




图 1 展示了兆易创新样本期内的基本特征。收盘价走势显示该股经历了从约 176 元到超过 800 元的大幅上涨行情，年化收益率达 42.82%。日收益率分布近似正态但呈现一定的尖峰厚尾

特征，体现了金融时间序列的典型波动聚集效应。月度收益率热力图显示，样本期内多数月份录得正收益，但波动较大。

三、方法论

3.1 特征工程

本项目构建了 36 个预测特征，涵盖价格衍生特征、技术指标特征、新增高级特征和滞后特征四大类别。价格衍生特征包括 1 日/5 日/10 日/20 日收益率、日内振幅比和涨跌幅比等 6 项；技术指标特征包括 20 日均线及其偏离度、均线交叉信号、20 日滚动标准差、14 日 ATR、布林带（上轨/下轨/带宽）、14 日 RSI、MACD（DIF/DEA/柱状图）、OBV 能量潮及相对成交量等 13 项；新增高级特征包括量价背离信号、Carhart 风格动量因子、相对强度、波动率比、20 日偏度和峰度等 6 项；滞后特征为核心指标的 1 日滞后项共 6 项。




图 2 特征相关性矩阵与 Top10 特征重要性

左图展示了 36 个特征之间的 Pearson 相关系数矩阵（层次聚类排序），右上三角遮罩避免重复。右图展示了与目标变量（未来 20 日涨跌方向）绝对相关性最高的 Top10 特征，红色表示正相关（增加上涨概率），蓝色表示负相关。布林带宽度（bb_width）、20 日滚动标准差（std_20）和 OBV 能量潮是与目标变量相关性最高的三个指标。

3.2 标签构造

标签以未来 20 个交易日的收盘价相对于当前收盘价的收益率为基础，将收益率处于前 30% 分位的样本标记为“涨”（1），后 30% 分位的样本标记为“跌”（0），中间 40% 的弱信号样本予以剔除。经处理，最终保留 604 个有效样本，其中上涨样本 315 个（52.15%），下跌样本 289 个（47.85%），类别分布基本均衡。

3.3 Purged Walk-Forward 交叉验证

本项目采用 5 折 Purged Walk-Forward Cross-Validation 作为评估框架，在训练集与测试集之间引入 20 个交易日的 purging 缓冲区（gap=20），有效避免了滞后特征从训练集泄漏到测试集。5 折划分如下：Fold 1 训练 84 条→测试 100 条；Fold 2 训练 184 条→测试 100 条；Fold 3 训练 284 条→测试 100 条；Fold 4 训练 384 条→测试 100 条；Fold 5 训练 484 条→测试 100 条。最终评估指标取 5 折均值。

四、模型评估与分析

以下分别对四个模型进行单独的评估分析。评估维度包括 5 折交叉验证的 AUC 均值、最后一折 ROC 曲线、特征重要性排序、模拟交易策略的年化收益率、夏普比率和胜率。

4.1 逻辑回归（Logistic Regression）

5 折 AUC 均值	0.712	最后一折 AUC	0.910
年化收益率	+572.00%	胜率	81.82%
夏普比率	4.020		
最大回撤	-11.25%		




图 3.1a 逻辑回归（Logistic Regression）ROC 曲线




图 3.1b 逻辑回归（Logistic Regression）特征重要性




图 3.1c 逻辑回归（Logistic Regression）模拟交易净值与回撤曲线

逻辑回归作为线性分类器的代表，模型可解释性强。其 5 折 AUC 均值 0.712 为四个模型中最高，说明其排序能力在多个时间窗口上整体稳定。特征重要性分析显示，布林带宽度（bb_width）和 20 日波动率（std_20）是最重要的两个特征，说明该模型主要依赖波动率结构变化进行判断。模拟交易年化收益率+572%、夏普比率 4.020 表现优异，最大回撤仅-11.25%，风险控制最佳。但 Fold 4 的 AUC 仅为 0.420，说明在某些市场环境下表现不稳定。

4.2 随机森林（Random Forest）

5 折 AUC 均值	0.568	最后一折 AUC	0.571
年化收益率	+857.21%	胜率	59.60%
夏普比率	3.387		
最大回撤	-26.44%		




图 3.2a 随机森林（Random Forest）ROC 曲线




图 3.2b 随机森林（Random Forest）特征重要性




图 3.2c 随机森林（Random Forest）模拟交易净值与回撤曲线

随机森林 5 折 AUC 均值 0.568，略高于随机基准但波动较大。OBV 能量潮和布林带下轨是最重要特征。模拟交易年化收益率+857%，但最大回撤达-26.44%，说明在某些时间段出现连续误判。Fold 5 的 Recall 为 0.974，即模型高度倾向于预测上涨，在持续上升行情中表现优异，但下跌行情中抗风险能力较弱。

4.3 XGBoost

5 折 AUC 均值	0.573	最后一折 AUC	0.670
年化收益率	+787.63%	胜率	66.67%
夏普比率	3.399		
最大回撤	-24.28%		




图 3.3a XGBoostROC 曲线




图 3.3b XGBoost 特征重要性




图 3.3c XGBoost 模拟交易净值与回撤曲线

XGBoost 的 5 折 AUC 均值为 0.573，与随机森林接近。macd_hist_lag2 和布林带上轨是最重要特征，体现对动量指标和价格边界信号的敏感度。模拟交易年化收益率+787.63%，最大回撤-24.28%，胜率 66.67%，整体介于随机森林和逻辑回归之间，具有较好的平衡性。

4.4 支持向量机（SVC）

5 折 AUC 均值	0.694	最后一折 AUC	0.916
年化收益率	+1047.71%	胜率	79.80%
夏普比率	4.734		
最大回撤	-11.25%		




图 3.4a 支持向量机 (SVC) ROC 曲线




图 3.4b 支持向量机 (SVC) 特征重要性




图 3.4c 支持向量机 (SVC) 模拟交易净值与回撤曲线

支持向量机 (线性核) 5 折 AUC 均值 0.694, 与逻辑回归接近。最后一折 AUC 达 0.916, 为所有模型中最高。std_20、macd 和 macd_signal 是最重要特征。模拟交易年化收益率 +1047.71%、夏普比率 4.734、最大回撤仅 -11.25%、胜率 79.80%, 四项指标综合最优, 被评为综合最佳模型。线性 SVM 的最大间隔分类特性使其在小样本高维空间具有良好泛化能力。

五、模型横向对比




图 4 四个模型横向对比（ROC 叠图、分类指标、交易指标）

模型	5 折 AUC	末折 AUC	年化收益率	夏普比率	最大回撤	胜率
逻辑回归	0.712	0.910	+572.00%	4.020	-11.25%	81.82%
随机森林	0.568	0.571	+857.21%	3.387	-26.44%	59.60%
XGBoost	0.573	0.670	+787.63%	3.399	-24.28%	66.67%
SVC	0.694	0.916	+1047.71%	4.734	-11.25%	79.80%

表 1 四个模型核心评估指标对比

综合来看，支持向量机（SVC）以夏普比率 4.734 和 AUC 均值 0.694 被选为综合最佳模型。从 ROC 叠图（图 4 左）可以看出，逻辑回归和 SVC 的 ROC 曲线更靠近左上角，AUC 值显著高于树模型（随机森林和 XGBoost），说明线性分类器在该时序分类任务中的排序能力优于集成树。分类指标对比（图 4 中）显示，随机森林的 Precision 最高（0.783），但其 Recall 较低（0.522），在"减少误买入"场景下具有优势。交易指标对比（图 4 右）则展现了 SVC 在夏普比率上的绝对领先。

需要指出的是，模拟交易的年化收益率基于仅 100 个交易日的测试数据，存在较大的统计不确定性，不应被过度解读为未来收益承诺。夏普比率和最大回撤作为风险调整后的指标，相对更能反映模型的真实预测能力。

六、结论与建议

本报告基于兆易创新日线数据，构建了四种机器学习分类模型进行未来 20 日涨跌方向预测，主要结论如下。

第一，线性分类器（逻辑回归和线性 SVM）在金融时序预测任务中表现优于树模型，其 5 折 AUC 均值分别为 0.712 和 0.694，显著高于随机森林（0.568）和 XGBoost（0.573）。这可能是因为小样本高维场景下，线性模型的正则化训练策略比集成树的贪婪生长更稳健。

第二，特征重要性分析表明，波动率相关特征（布林带宽度、20 日滚动标准差）和成交量相关特征（OBV 能量潮）是预测未来涨跌方向最重要的信号，而传统动量指标（MACD）的重要性相对较低。这暗示量能变化和波动率结构变化先于价格本身的变动。

第三，综合最佳模型为支持向量机（线性核），其在测试集上实现了夏普比率 4.734、最大回撤仅-11.25%的优秀表现。但该结论基于 2025 年 12 月至 2026 年 6 月的数据，该时间段恰逢市场整体上行，模型的顺周期表现可能部分归因于市场环境。

后续改进方向：（1）引入更多维度特征，如行业相对强度、宏观因子等；（2）使用集成策略对多个模型进行融合；（3）在更长的时间跨度和更多股票上进行验证，检验模型的可迁移性；（4）结合深度学习方法（如 LSTM）捕捉长时序依赖关系。